

Task 1

Analizamos los siguientes resultados. Primero, hemos cogido varias analogías que ponen de manifiesto la relación semántica que capturan los embeddings.

Para king - man + woman, vemos que para la palabra queen aparece en general en segundo puesto (la primera es king). Esto es matemáticamente esperable ya que el vector resultante permanece muy próximo al original. La aparición de queen en segundo lugar confirma que la dirección del cambio semántico es correcta, aunque la magnitud del desplazamiento no sea suficiente para alejarlo del punto de partida king.

Al aumentar la dimensión del embedding, vemos que el valor de la distancia coseno disminuye, debido a la esparsidad de los vectores, mientras que el del producto aumenta, debido a un módulo mayor. Esto se repite para las otras analogías.

Es curioso que para la analogía colder - cold + hot, cuando usamos el dot product, la palabra hotter no aparece entre las 10 primeras para el embedding de 50 dimensiones. Las que sí aparecen son colder, petrino, temperatures, music/club.

Analogías por dimensión (Cosine y Dot Product)

Analogía	Dim	Target	Rank Cos	Rank Dot	Cosine	Dot
king - man + woman	50d	queen	2	3	0.8610	24.64
	100d	queen	2	2	0.7834	29.91
	300d	queen	2	2	0.6896	38.17
colder - cold + hot	50d	hotter	3	>10	0.8125	22.55
	100d	hotter	2	2	0.7616	28.47
	300d	hotter	1	1	0.7156	41.49
paris - france + spain	50d	madrid	3	3	0.8017	23.49
	100d	madrid	1	1	0.7962	29.49
	300d	madrid	1	1	0.7379	39.67
bigger - big + small	50d	smaller	4	3	0.8655	22.29
	100d	smaller	2	2	0.8575	26.74
	300d	smaller	2	1	0.7753	31.71

Pares Relacionados

Ahora analizamos la diferencia entre usar el dot product y la similitud coseno al calcular la similitud entre pares relacionados y no relacionados.

Es difícil hacer una comparación justa entre ambos, ya que utilizan escalas diferentes. La similitud coseno es más fácil de interpretar, ya que está acotada entre 0 y 1, mientras que el dot product no.

Notamos lo que ya mencionábamos antes, que al aumentar la dimensión del embedding, el valor de la distancia coseno disminuye, debido a la esparsidad de los vectores, mientras que el del producto aumenta, debido a un módulo mayor.

Palabra 1	Palabra 2	50d Cos	50d Dot	100d Cos	100d Dot	300d Cos	300d Dot
king	queen	0.7839	21.88	0.7508	27.59	0.6336	30.78
cat	dog	0.9218	19.74	0.8798	25.00	0.6817	28.78
happy	joyful	0.5550	11.04	0.5260	12.32	0.4751	15.16
car	vehicle	0.8834	27.46	0.8631	32.49	0.7655	35.86
doctor	nurse	0.7977	19.29	0.7522	22.12	0.5860	23.54
sun	moon	0.6543	17.12	0.6138	22.21	0.4807	24.72
coffee	tea	0.8080	20.95	0.7733	26.54	0.6692	32.34
france	paris	0.8025	26.57	0.7482	31.54	0.6581	34.27
PROMEDIO		0.7758	20.51	0.7384	24.98	0.6187	28.18

Pares No Relacionados

Palabra 1	Palabra 2	50d Cos	50d Dot	100d Cos	100d Dot	300d Cos	300d Dot
king	banana	0.2207	5.76	0.1609	5.35	0.0666	3.06
cat	democracy	0.0368	0.97	0.0840	2.69	0.0007	0.03
happy	refrigerator	0.1862	4.43	0.1670	4.95	0.0350	1.27
car	philosophy	0.0427	1.38	0.0919	3.45	0.0126	0.58
doctor	volcano	0.1447	4.09	0.0665	2.31	-0.0126	-0.62
sun	keyboard	0.1990	5.67	0.0584	2.13	0.0711	3.75
coffee	elephant	0.2532	6.02	0.1829	5.35	0.1410	6.46
france	purple	0.1403	4.29	0.1283	4.55	0.0616	3.03
PROMEDIO		0.1529	4.08	0.1175	3.85	0.0470	2.20